

Ford İkinci El Araç Fiyatlarının Makine Öğrenmesi ile Tahmini

Regresyon Tabanlı Makine Öğrenmesi Projesi

1. Problem Tanımı

İngiltere ikinci el araç piyasasında Ford marka araçların ilan fiyatlarının, aracın model, üretim yılı, vites tipi, kilometre, yakıt tipi, vergi (tax), yakıt tüketimi (mpg) ve motor hacmi gibi özelliklerine dayanarak tahmin edilmesi amaçlanmıştır. Girdi olarak araç özellikleri, çıktı olarak sayısal bir satış fiyatı (£) üretilmektedir. Böyle bir model, alıcı ve satıcılara piyasa koşullarına uygun, veriye dayalı bir fiyat referansı sunar.

2. Veri Seti


Bu projede Ford İkinci El Araç Fiyatları veri seti (ford.csv, 100,000 UK Used Car Data Set ailesinden) kullanılmıştır. Veri seti 17.965 satır ve 9 değişken içermektedir:

- model — araç modeli (Fiesta, Focus, Kuga, Mustang vb.)
- year — üretim yılı
- price — satış fiyatı, £ (hedef değişken)
- transmission — vites tipi (Manual, Automatic, Semi-Auto)
- mileage — kilometre
- fuelType — yakıt tipi (Petrol, Diesel, Hybrid, Electric, Other)
- tax — yıllık vergi tutarı
- mpg — yakıt tüketimi (mil/galon)
- engineSize — motor hacmi (litre)


Veri setinde eksik (null) değer bulunmamaktadır; tüm 9 sütun 17.965 satırda da doludur.

3. Veri Analizi ve Ön İşleme


3.1 Veri Keşfi (EDA)




Şekil 1. Satış fiyatı dağılımı — sağa çarpık, çoğu araç £5.000-£20.000 aralığında.



Şekil 2. Kilometre - fiyat ilişkisi (1.000 örneklem) — beklenen negatif ilişki: kilometre arttıkça fiyat düşüyor.



Şekil 3. Vites türüne göre fiyat dağılımı — Automatic ve Semi-Auto araçlar Manual'a göre daha yüksek fiyat aralığında.



Şekil 4. Değişkenler arası korelasyon matrisi — fiyat ile en güçlü ilişkiler year (+0.64) ve mileage (-0.53).

Korelasyon matrisine göre satış fiyatını en çok etkileyen sayısal değişkenler üretim yılı (+0.64) ve kilometre (-0.53) olarak öne çıkmaktadır; motor hacmi (+0.41) ve vergi (+0.41) de orta düzeyde pozitif ilişki göstermektedir. Yakıt tüketimi (mpg) ile fiyat arasında negatif bir ilişki (-0.35) vardır — bu beklenen bir sonuçtur, çünkü yüksek performanslı/büyük motorlu araçlar hem daha pahalı hem de yakıt tüketimi (mpg) daha düşüktür.

3.2 Uygulanan Ön İşleme Adımları

- Eksik değer kontrolü yapılmış, veri setinde eksik değer bulunmadığından dropna() işlemi veri kaybına yol açmamıştır.
- Hedef değişken (price) ayrılmış, kalan sütunlar özellik (X) olarak belirlenmiştir.
- Kategorik değişkenler (model, transmission, fuelType) one-hot encoding (pd.get_dummies, drop_first=True) ile sayısallaştırılmıştır.
- Veri, %80 eğitim (14.372 araç) - %20 test (3.593 araç) olacak şekilde bölünmüştür.
- Sayısal değişkenler arasındaki ölçek farkını (örn. kilometre onbinlerce, motor hacmi 1-2 aralığında) gidermek için StandardScaler uygulanmıştır. Veri sızıntısını (data leakage) önlemek için scaler yalnızca eğitim setine fit edilmiş, test setine sadece transform uygulanmıştır.

4. Model / Yöntem

Bu regresyon probleminde iki model karşılaştırmalı olarak uygulanmıştır:

- Linear Regression: Değişkenler ile fiyat arasındaki doğrusal ilişkiyi ölçen, yorumlanabilir bir başlangıç (baseline) modeli olarak seçilmiştir.
- Random Forest Regressor (n_estimators=100): Model, yıl ve kilometre gibi değişkenlerin fiyatla doğrusal olmayan bir ilişki içinde olabileceği öngörüsüyle, karmaşık etkileşimleri yakalayabilen bir ensemble yöntemi olarak tercih edilmiştir.


5. Eğitim / Uygulama Süreci

Her iki model de ölçeklendirilmiş eğitim verisi (X_train_scaled, y_train) üzerinde eğitilmiştir. Random Forest için ağaç sayısı (n_estimators) 100 olarak belirlenmiş, random_state=42 ile tekrarlanabilirlik sağlanmıştır.


6. Değerlendirme Sonuçları

Model	MAE	RMSE	R ²
Linear Regression	£1.368,83	£1.838,36	0.849
Random Forest	£860,47	£1.253,82	0.930

Random Forest, tüm metriklerde Linear Regression'dan belirgin şekilde üstündür (R^2 : 0.930 vs 0.849). Ortalama mutlak hata (MAE) Random Forest'ta £860 iken Linear Regression'da £1.369'dur — yani Random Forest ortalamada araç fiyatını yaklaşık %37 daha az hatayla tahmin etmektedir.



Şekil 5. Random Forest - fiyat tahmininde en önemli özellikler. 'year', 'engineSize' ve 'mileage' en belirleyici değişkenler.



Şekil 6. Gerçek fiyatlar ve Random Forest model tahminleri — noktaların büyük çoğunluğu kusursuz tahmin çizgisine (kırmızı kesikli) yakın toplanmıştır.

7. Hata Analizi

Feature importance grafiğine göre Random Forest modelinde fiyatı belirlemede en etkili değişkenler sırasıyla year (üretim yılı, ~%48), engineSize (motor hacmi, ~%25) ve mileage (kilometre, ~%7) olmuştur. Model ismi (örn. model_Kuga, model_Fiesta, model_Mustang) gibi kukla değişkenler ise tek başlarına daha düşük ama gözle görülür bir etkiye sahiptir.

Gerçek vs. tahmin grafiğinde noktaların büyük kısmı kusursuz tahmin çizgisine yakın toplanmakla birlikte, özellikle yüksek fiyatlı araçlarda (muhtemelen performans/lüks modeller) sapma artmaktadır. En büyük mutlak hataya sahip 5 araç incelendiğinde:

Gerçek Fiyat	Tahmin Edilen Fiyat	Mutlak Hata
£38.015	£12.286,78	£25.728,22
£15.999	£5.656,42	£10.342,58
£30.000	£21.276,46	£8.723,54
£17.999	£24.795,79	-£6.796,79
£30.999	£24.517,18	£6.481,82

En büyük hata (£25.728), gerçek fiyatı £38.015 olan bir aracın yalnızca £12.287 olarak tahmin edilmesinden kaynaklanmıştır — bu, muhtemelen veri setinde az örneği bulunan bir model/donanım kombinasyonuna (örn. yüksek performanslı bir ST/Sportif versiyon) işaret etmektedir; model bu tür nadir-yüksek-fiyatlı örnekleri genelleştirmekte zorlanmaktadır. Benzer şekilde tabloda hem düşük tahmin (pozitif hata) hem yüksek tahmin (negatif hata) örnekleri bulunması, hatanın sistematik bir yönde değil, veri setinde az temsil edilen uç segmentlerde (çok pahalı veya sıra dışı özellik kombinasyonuna sahip araçlar) yoğunlaştığını göstermektedir.

8. Sonuç ve Geliştirme Önerileri

Bu çalışmada, Ford ikinci el araç fiyatlarının tahmininde Random Forest modelinin Linear Regression'a göre belirgin şekilde daha başarılı olduğu gösterilmiştir (R^2 : 0.930 vs 0.849). Modelin geliştirilmesi için aşağıdaki adımlar önerilmektedir:

- GridSearch/RandomSearch ile Random Forest hiperparametrelerinin (n_estimators, max_depth, min_samples_leaf) optimize edilmesi.
- XGBoost veya LightGBM gibi gradyan artırma (gradient boosting) tabanlı modellerin denenerek performansın karşılaştırılması.
- Az örnekli model kategorilerinin ('model_' sütunlarında düşük frekanslı olanlar) gruplanması veya bu segmentler için ayrı bir alt model denenmesi.
- Yüksek fiyatlı/nadir araç segmentindeki hatayı azaltmak için hedef değişkene log-dönüşüm uygulanması.

Kaynakça

Veri Seti: Ford Used Car Listing (ford.csv) — 100,000 UK Used Car Data Set, Kaggle.